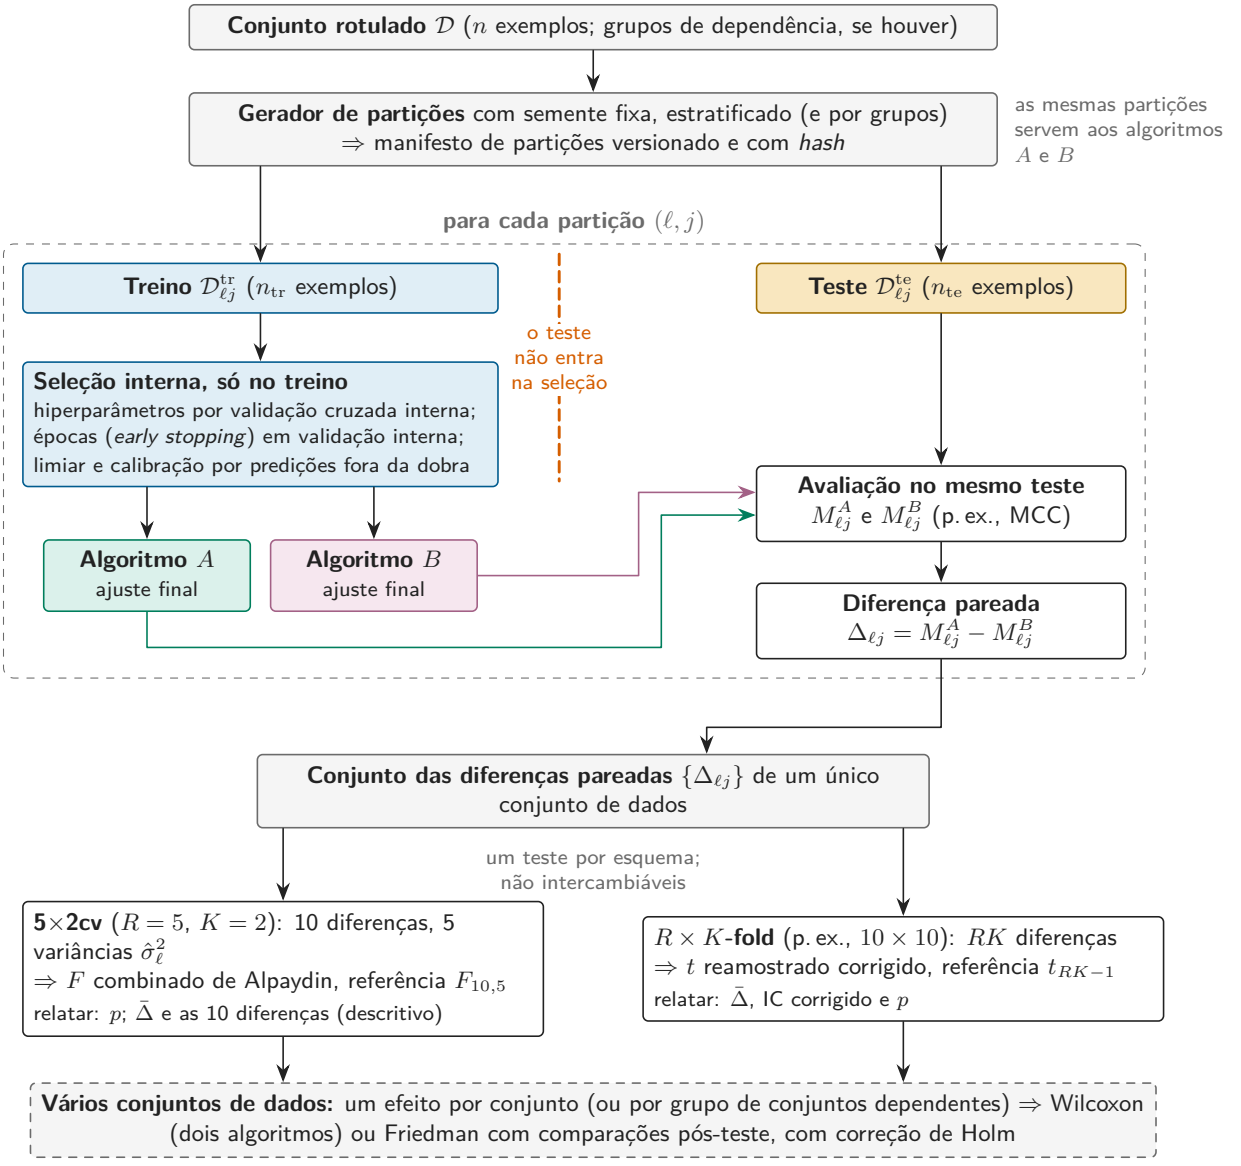

Conjunto rotulado $\mathcal{D}$ (n exemplos; grupos de dependência, se houver)
Gerador de partições com semente fixa, estratificado (e por grupos)
⇒ manifesto de partições versionado e com hash
as mesmas partições servem aos algoritmos A e B
para cada partição (ℓ, j)
Treino $\mathcal{D}_{\ell j}^{\mathrm{tr}}$ (n_{tr} exemplos)
Teste $\mathcal{D}_{\ell j}^{\mathrm{te}}$ (n_{te} exemplos)
o teste não entra na seleção
Seleção interna, só no treino
hiperparâmetros por validação cruzada interna;
épocas (early stopping) em validação interna;
limiar e calibração por predições fora da dobra
Algoritmo A
ajuste final
Algoritmo B
ajuste final
Avaliação no mesmo teste
$M_{\ell j}^{A}$ e $M_{\ell j}^{B}$ (p. ex., MCC)
Diferença pareada
$\Delta_{\ell j} = M_{\ell j}^{A} - M_{\ell j}^{B}$
Conjunto das diferenças pareadas $\{\Delta_{\ell j}\}$ de um único conjunto de dados
um teste por esquema; não intercambiáveis
5×2cv ($R = 5$, $K = 2$): 10 diferenças, 5 variâncias $\hat{\sigma}_{\ell}^{2}$
⇒ F combinado de Alpaydin, referência $F_{10,5}$
relatar: p; $\bar{\Delta}$ e as 10 diferenças (descritivo)
$R \times K$-fold (p. ex., 10×10): RK diferenças
⇒ t reamostrado corrigido, referência t_{RK-1}
relatar: $\bar{\Delta}$, IC corrigido e p
Vários conjuntos de dados: um efeito por conjunto (ou por grupo de conjuntos dependentes) ⇒ Wilcoxon (dois algoritmos) ou Friedman com comparações pós-teste, com correção de Holm